

REPORTING D'UNE ANALYSE MULTIVARIÉE

Analyse de l'offre de céréales vendues en France

Adrien Guille - SAE 4.02 - Université Lumière Lyon 2



Un data scientist perplexe face à la composition de ses céréales - Image générée par Gemini.

Contexte

Open Food Facts est une base de données (~4,5 millions de lignes et plus de 200 colonnes, totalisant 9 Go) collaborative et libre qui recense les caractéristiques de centaines de milliers de produits alimentaires à travers le monde. Elle recelle une multitude d'informations brutes issues des emballages, telles que la liste des ingrédients, les valeurs nutritionnelles, les allergènes, les éventuels labels ou les Nutri-Score et Eco-Score.

Objectif

Pour cette SAE, vous travaillerez sur une petite partie de la base de données, à savoir, celle qui concerne les céréales pour le petit-déjeuner commercialisées en France. C'est a priori un vaste marché ciblant un public varié (enfants, adultes, sportifs, régimes spécifiques), avec une offre hétérogène tant du point de vue nutritionnel qu'environnemental, allant de produits bruts, très simples, à des produits ultra-transformés.

L'objectif est de proposer une manière de déchiffrer ce marché par l'intermédiaire d'une analyse des corrélations entre caractéristiques et entre produits, en s'appuyant sur les méthodes factorielles vues en cours (ACP, AFC, ACM) et les méthodes de classification non supervisées vues en cours (classification hiérarchique, k-moyennes).

Étapes

Préparation des données

- Identification des variables
- Gestion des valeurs manquantes
- Gestion des doublons
- Gestion des valeurs aberrantes
- Rencodage / Création de variables

Pré-analyse

- Calcul d'indicateurs univariés
- Calcul et visualisation d'indicateurs bivariés

Analyse factorielle / Classification non supervisée

- Choix de scénarios d'analyse
- Choix des variables à analyser / variables illustratives pour chaque scénario
- Choix de la ou les méthodes pertinentes pour chaque scénario
- Applications des méthodes
 - Commentaire technique des résultats
 - Conclusions "métier"

Automatisation

- Création d'une interface permettant de reproduire les résultats, avec, au choix :
 - R + Shiny
 - Python + Streamlit
- L'interface et les traitements de données doivent être suffisamment génériques pour permettre le chargement et l'analyse d'une autre sous-partie de la base de données

Livrables et évaluation

Soutenance / démonstration - 1/3 de la note finale

Lors d'une soutenance vous présenterez les résultats obtenus pour un scénario d'analyse, le but étant (1) de montrer que votre interface est fonctionnelle et (2) que vous savez lire et interpréter les résultats qu'elles présentent tant d'un point de vue technique que "métier".

Vous chargerez et analyserez un nouveau fichier de données, mis à disposition pour la soutenance, pour montrer l'adaptabilité de votre interface.

Dossier - 1/3 de la note finale

Vous rendrez une synthèse de votre étude sous la forme d'un document (obligatoirement au format PDF) d'au plus 4 pages, suivant ce plan :

- Brève description des données étudiées
- Scénarios d'analyse
- Méthodologie, commentaire technique et lecture "métier" des résultats obtenus
- Conclusion générale sur le marché étudié

Évaluation individuelle - 1/3 de la note finale

Une brève épreuve individuelle, sur table, évaluera votre capacité à lire et interpréter les résultats obtenus avec des méthodes d'analyse factorielle et de classification non supervisée.

Organisation et calendrier

- La SAE est à traiter en groupes (EMS et VCOD mélangés), tirés aléatoirement (cf. composition des groupes sur Moodle).
- **8 juin à partir de 15H30** : point obligatoire avec tous les groupes se tiendra à l'IUT, afin que je m'assure que votre travail va dans la bonne direction, et vous réaiguille si nécessaire.
- **22 juin avant 17H30** : rendu du dossier sur Moodle.
- **22 juin avant 20H00** : rendu de l'interface utilisateur sur Moodle.
- **24 juin à 8H00** : évaluation individuelle.
- **24 juin à partir de 10H00** : soutenances.